

Triagem Binária de Células Cervicais em Esfregaços Convencionais com ConvNeXt-Tiny e Particionamento por Imagem

Karielly de Carvalho¹

¹ Universidade Federal do Piauí (UFPI)

karielly.carvalho@ufpi.edu.br

Resumo. Este trabalho avalia a triagem binária de células cervicais em esfregaços convencionais de Papanicolau usando ConvNeXt-Tiny na coleção CRIC Cervix. Para reduzir vazamento entre recortes visualmente correlatos, a avaliação principal usa validação cruzada em cinco folds agrupada por imagem-fonte. O protocolo obteve AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$. Na partição retida, a análise de limiares evidenciou a troca entre falsos negativos e falsos positivos, com sensibilidade de 0,9701 e especificidade de 0,8723 no regime de alta sensibilidade. A análise Bethesda indicou ASC-US como principal dificuldade. O método é um protótipo de pesquisa para priorização, não um sistema diagnóstico.

1. Introdução

O câncer do colo do útero permanece entre as principais causas evitáveis de morbidade e mortalidade por câncer em mulheres. Estimativas globais para 2020 indicam aproximadamente 604 mil novos casos e 342 mil mortes, com maior carga em regiões que enfrentam restrições de acesso à vacinação, ao rastreamento e ao tratamento oportuno [Singh et al. 2023]. A citologia cervical continua sendo um componente relevante do rastreamento, mas a leitura manual de lâminas é trabalhosa, depende de especialistas e envolve alterações morfológicas que podem ser sutis, especialmente nas categorias limítrofes.

Redes neurais profundas têm apresentado resultados promissores na análise de imagens citológicas [Jiang et al. 2023, Xu et al. 2023]. Entretanto, revisões recentes mostram que a comparação entre métodos é dificultada por diferenças de base, preparação da lâmina, tarefa, granularidade dos rótulos e protocolo de validação [Fang et al. 2024]. Um risco central ocorre quando células recortadas da mesma imagem aparecem em treino e teste: elas compartilham coloração, aquisição, fundo e artefatos, podendo inflar a estimativa de generalização quando o particionamento não controla essa dependência.

Além da discriminação, um sistema de apoio à triagem precisa tornar explícita a relação entre falsos negativos e falsos positivos. Um limiar fixo de 0,5 pode não ser adequado quando omitir uma célula anormal é mais grave do que encaminhar uma célula normal para revisão. Probabilidades também exigem calibração [Guo et al. 2017], e diretrizes como TRIPOD+AI reforçam a necessidade de relatar partições, limiares, incerteza e uso pretendido [Collins et al. 2024].

Este artigo estuda a classificação binária *normal versus anormal* de células da coleção CRIC Cervix, obtidas por citologia convencional. A tarefa é formulada como triagem: ASC-US, LSIL, ASC-H, HSIL e SCC compõem a classe anormal, mas os subtipos são preservados para análise posterior. Usa-se ConvNeXt-Tiny pré-treinada [Liu et al. 2022] para avaliar até que ponto um classificador pode priorizar células suspeitas em imagens convencionais.

As contribuições são avaliar a ConvNeXt-Tiny na CRIC Cervix com separação por imagem-fonte, analisar limiares operacionais de triagem, comparar exploratoriamente com ResNet50 na mesma partição retida e interpretar os erros pelas categorias Bethesda.

2. Trabalhos Relacionados

2.1. Bases e tarefas em citologia cervical

Bases como Herlev e SIPaKMeD são frequentes em estudos de classificação cervical [Jiang et al. 2023, Fang et al. 2024]. A SIPaKMeD reúne células extraídas de esfregaços de Papanicolau para classificação por atributos e imagens [Plissiti et al. 2018]. Embora úteis para comparação, bases de células isoladas não reproduzem integralmente sobreposição, inflamação, variação de fundo e outros fatores encontrados em exames convencionais.

A CRIC Cervix foi construída a partir de 400 imagens de citologia convencional e contém 11.534 células classificadas por citopatologistas [Rezende et al. 2021]. A coleção inclui NILM, ASC-US, LSIL, ASC-H, HSIL e SCC, preservando desafios de lâminas reais, como células sobrepostas e elementos inflamatórios. Por isso, é útil para estudar variação entre imagens, desde que a dependência entre células da mesma imagem seja considerada.

2.2. Aprendizado profundo para classificação cervical

Estudos recentes reportam desempenho elevado com redes profundas em Herlev, SIPaKMeD e outras bases de citologia cervical. Kaur et al. compararam modelos de transferência e reportaram 95% de acurácia com ResNet50 em Herlev binário [Kaur et al. 2025]; Mehedi et al. obtiveram 98,53% de acurácia com CCanNet em SIPaKMeD de cinco classes [Mehedi et al. 2024]; e Lima et al. reportaram 98,35% em Herlev binário e 99,73% em SIPaKMeD binário com *ensembles* [Lima et al. 2025]. Esses resultados, embora fortes, não são diretamente comparáveis ao presente estudo por diferenças de base, preparação, número de classes, métrica principal e unidade de particionamento.

Em citologia convencional, Rodríguez et al. reportaram sensibilidade 0,688 e especificidade 0,762 em esfregaços de Papanicolau, indicando maior dificuldade que em bases de células isoladas ou citologia em meio líquido [Rodríguez et al. 2024]. Este trabalho se diferencia pelo protocolo: CRIC, separação por imagem, validação cruzada agrupada, limiares definidos na validação, incerteza por bootstrap agrupado, comparação local com ResNet50 e análise de erro por nomenclatura Bethesda.

3. Metodologia

3.1. Base de dados e definição do desfecho

Foram utilizadas as 400 imagens e as 11.534 anotações celulares da CRIC Cervix [Rezende et al. 2021]. A classe normal reúne as 6.779 células rotuladas como negativas

para lesão intraepitelial ou malignidade (NILM). A classe anormal reúne 4.755 células: 606 ASC-US, 1.360 LSIL, 925 ASC-H, 1.703 HSIL e 161 SCC, segundo a nomenclatura do Sistema Bethesda [Nayar and Wilbur 2015]. A escolha binária representa um primeiro estágio de priorização e não substitui a classificação Bethesda. A CRIC não disponibiliza identificadores de paciente; portanto, a imagem-fonte é o nível de agrupamento mais alto disponível, mas não assegura separação entre pacientes.

Para cada anotação, foi gerado um recorte RGB de 224×224 pixels centrado na coordenada do núcleo. Recortes que ultrapassavam as bordas foram completados com fundo branco. Não foi realizada segmentação do núcleo ou do citoplasma, permitindo que a rede utilizasse o contexto celular local, incluindo variações de coloração, textura, agrupamento e fundo. A Figura 1 resume o fluxo de processamento e decisão.




Figura 1. Fluxo geral do protocolo proposto, desde a imagem convencional da CRIC Cervix até a decisão binária por limiar operacional. Os aumentos de dados são aplicados durante o treinamento.

3.2. Particionamento e desenho de avaliação

A unidade de agrupamento foi a imagem original. Um `GroupShuffleSplit` separou 70% das imagens para treino e 30% para um conjunto temporário, depois dividido igualmente entre validação e teste. Assim, nenhuma imagem-fonte contribuiu com células para mais de uma partição. A Tabela 1 apresenta a distribuição obtida com semente 42.

Tabela 1. Distribuição das células e imagens nas partições.

Partição	Imagens	Normal	Anormal	Total
Treino	280	4.698	2.835	7.533
Validação	60	938	916	1.854
Teste	60	1.143	1.004	2.147

Essa decisão reduz o risco de vazamento por correlação visual. A avaliação primária empregou `StratifiedGroupKFold` com cinco folds, usando a imagem-fonte como grupo, retreinando o modelo em cada fold e avaliando as predições no limiar 0,50, sem TTA. A partição treino–validação–teste da Tabela 1 foi mantida para análise complementar de TTA, calibração, limiares selecionados na validação, intervalos de confiança e erro por categoria Bethesda.

3.3. Modelo e treinamento

A arquitetura principal foi ConvNeXt-Tiny pré-treinada na ImageNet [Liu et al. 2022, Deng et al. 2009], com a cabeça substituída por uma camada linear de duas saídas. Como comparação interna, uma ResNet50 pré-treinada [He et al. 2016] foi avaliada na mesma partição retida; essa comparação não substitui a validação cruzada, mas fornece referência sob igual divisão treino–validação–teste.

O treinamento utilizou AdamW [Loshchilov and Hutter 2019]. No treino, foram aplicados recorte redimensionado aleatório com escala entre 0,85 e 1,0, espelhamento horizontal, rotação de até 10 graus e pequenas variações de brilho, contraste, saturação e matiz. As imagens foram normalizadas pelas estatísticas da ImageNet [Deng et al. 2009]. Um `WeightedRandomSampler` equilibrou a exposição às classes sem alterar a distribuição de validação ou teste.

A Tabela 2 resume configuração e custo computacional [Lima et al. 2025]. Após substituir a cabeça de 1.000 por duas saídas, o modelo possui aproximadamente 27,82 milhões de parâmetros e custo de referência de 4,46 GFLOPs para entrada 224×224 . O melhor checkpoint foi selecionado pela AUC ROC na validação.

Tabela 2. Hiperparâmetros de treinamento e características do protocolo local.

Parâmetro	Configuração	Parâmetro	Configuração
Arquitetura	ConvNeXt-Tiny	Baseline	ResNet50
Entrada	$224 \times 224 \times 3$	Lote	48
Otimizador	AdamW	Taxa inicial	3×10^{-4}
Decaimento	10^{-4}	Épocas máx.	12
Agendador	cossenoidal	<i>Label smoothing</i>	0,03
Amostragem	ponderada	Parâmetros	27,82 M
Custo ref.	4,46 GFLOPs	Seleção	AUC ROC val.

3.4. Predição, limiares e calibração

Na análise da partição retida, foi aplicada *test-time augmentation* (TTA) pela média dos logits da imagem original e de seu espelho horizontal. A calibração por temperatura ajustou um único parâmetro T minimizando entropia cruzada na validação [Guo et al. 2017]. Como o escalonamento por temperatura é monotônico, ele não altera a ordenação das predições nem as AUCs; qualquer mudança de ranqueamento em relação à inferência sem TTA decorre do TTA, não da temperatura.

Foram avaliados três regimes de decisão: limiar 0,5; limiar de Youden, maximizando sensibilidade e especificidade na validação; e limiar de alta sensibilidade, selecionando o menor custo em falsos positivos entre pontos com sensibilidade mínima de 0,97. Os limiares resultantes foram 0,287 para Youden e 0,099 para alta sensibilidade. Nenhum limiar foi otimizado no teste.

3.5. Métricas e análise de incerteza

Foram calculadas AUC ROC, AUC precisão–revocação (AUC PR), sensibilidade, especificidade, acurácia balanceada, $F1$ da classe anormal, coeficiente de correlação de Matthews (MCC), kappa de Cohen e *Brier score*. A calibração foi resumida pelo erro esperado de calibração (ECE) em dez intervalos.

Para o regime de Youden, intervalos de confiança de 95% foram estimados com 2.000 réplicas de bootstrap. A reamostragem ocorreu sobre as 60 imagens de teste, com reposição, incluindo em cada réplica todas as células pertencentes às imagens sorteadas. Essa estratégia evita tratar 2.147 células correlatas como observações completamente independentes.

Por fim, as predições binárias foram estratificadas pelas seis categorias Bethesda. Essa análise não transforma o modelo em multiclasse; ela identifica quais subtipos concentram erros e fornece uma interpretação mais útil do que uma única métrica agregada. A Tabela 6 usa as decisões da partição retida no limiar de Youden, 0,287.

4. Resultados

4.1. Validação cruzada agrupada

A validação cruzada agrupada em cinco folds constitui o resultado primário. No limiar 0,50 e sem TTA, a ConvNeXt-Tiny obteve AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$. A Tabela 3 resume as métricas agregadas e a Figura 2 mostra que a variação principal ocorre nas métricas dependentes do limiar, não no ranqueamento global.

Tabela 3. Resultado primário da validação cruzada em cinco folds agrupada por imagem, com limiar 0,50 e sem TTA. Valores em média $\pm$ desvio-padrão.

Métrica	Resultado
AUC ROC	$0,9709 \pm 0,0059$
AUC PR	$0,9607 \pm 0,0121$
Acurácia balanceada	$0,9091 \pm 0,0115$
Sensibilidade	$0,8994 \pm 0,0480$
Especificidade	$0,9188 \pm 0,0400$
<i>FI</i>	$0,8926 \pm 0,0128$
MCC	$0,8189 \pm 0,0208$
Kappa	$0,8164 \pm 0,0223$
<i>Brier score</i>	$0,0699 \pm 0,0079$




Figura 2. Métricas dependentes do limiar nos cinco folds agrupados. O fold 1 privilegia especificidade e perde sensibilidade; os folds 2 e 3 mostram o comportamento oposto.

A Figura 2 justifica reportar a validação cruzada além da AUC: no fold 1, a sensibilidade cai para 0,8253 enquanto a especificidade chega a 0,9681; nos folds 2 e 3, a recuperação de anormais aumenta, mas com menor especificidade. Portanto, a variação relevante para uso em triagem está no limiar operacional e na composição do fold, não apenas na capacidade de ranqueamento do modelo.

4.2. Análise detalhada em uma partição

Na partição retida, a inferência da ConvNeXt-Tiny com TTA produziu AUC ROC de 0,9832 e AUC PR de 0,9827. A temperatura estimada na validação foi $T = 1,210$ e o *Brier score* foi 0,0473. O ECE passou de 0,0247 para 0,0130 após o escalonamento, indicando melhora de calibração nessa partição. Como a temperatura é monotônica, ela não altera as AUCs; a pequena mudança de ranqueamento em relação à inferência sem TTA decorre do TTA.

4.3. Efeito do limiar operacional

Os três regimes evidenciam a troca entre falsos negativos e falsos positivos. O limiar 0,50 apresentou o maior MCC e a maior acurácia balanceada. O limiar de Youden aumentou a sensibilidade para 0,9522 com especificidade 0,9283. O regime de alta sensibilidade atingiu 0,9701 de sensibilidade, mas reduziu a especificidade para 0,8723, ponto aceitável apenas se a prioridade operacional for reduzir omissões e encaminhar mais casos para revisão humana. A Tabela 4 explicita essa troca em contagens absolutas: ao reduzir o limiar, os falsos negativos caem de 60 para 30, enquanto os falsos positivos sobem de 64 para 146.

Tabela 4. Matriz de decisão na partição retida para três regimes de limiar.

Regime	Limiar	TN	FP	FN	TP	Sens.	Espec.
0,50	0,500	1079	64	60	944	0,9402	0,9440
Youden	0,287	1061	82	48	956	0,9522	0,9283
Alta sens.	0,099	997	146	30	974	0,9701	0,8723

4.4. Comparação com ResNet50

A comparação interna com ResNet50 foi realizada na mesma partição retida. A ConvNeXt-Tiny apresentou maior capacidade de ranqueamento, com AUC ROC 0,9816 e AUC PR 0,9805, contra 0,9710 e 0,9750 da ResNet50. A ResNet50, por outro lado, obteve maior especificidade, acurácia balanceada e MCC no limiar avaliado. Esse resultado indica que a vantagem da ConvNeXt-Tiny não é absoluta: ela ordena melhor as amostras, enquanto a ResNet50 foi competitiva e mais favorável em algumas métricas dependentes do limiar. A comparação deve ser lida como exploratória, pois foi realizada apenas na partição retida, e não nos cinco folds agrupados.

Tabela 5. Comparação entre ConvNeXt-Tiny e ResNet50 na partição retida.

Modelo	AUC ROC	AUC PR	Acc. bal.	Sens.	Espec.	F1	MCC
ConvNeXt-Tiny	0,9816	0,9805	0,9371	0,9373	0,9370	0,9331	0,8738
ResNet50	0,9710	0,9750	0,9401	0,9064	0,9738	0,9362	0,8852

4.5. Representatividade e erros por categoria Bethesda

A composição da partição retida favorece categorias mais facilmente separáveis: HSIL corresponde a 52,7% das células anormais no teste, ante 35,8% no conjunto completo,

enquanto LSIL corresponde a 16,4%, ante 28,6% no conjunto completo. Essa super-representação de HSIL e sub-representação de LSIL ajudam a explicar por que os resultados da partição única são superiores às médias da validação cruzada.

No limiar de Youden, a Tabela 6 mostra 92,8% de acerto para NILM, 81,7% para ASC-US, 94,5% para LSIL, 90,2% para ASC-H, 99,4% para HSIL e 100% para SCC. O resultado de ASC-US, baseado em 115 células dessa partição, sugere uma dificuldade relevante, mas não sustenta sozinho uma conclusão populacional. SCC também possui suporte reduzido, com 42 células.

Tabela 6. Acerto binário por categoria Bethesda na partição retida, usando o limiar de Youden (0,287).

Categoria	<i>n</i>	Acerto (%)	IC95% Wilson	<i>P</i> (anormal) média
NILM	1143	92,8	91,2–94,2%	0,091
ASC-US	115	81,7	73,7–87,7%	0,741
LSIL	165	94,5	90,0–97,1%	0,898
ASC-H	153	90,2	84,5–94,0%	0,860
HSIL	529	99,4	98,3–99,8%	0,956
SCC	42	100,0	91,6–100,0%	0,970

5. Conclusão

A avaliação primária por validação cruzada agrupada mostrou AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$ para a ConvNeXt-Tiny na triagem binária de células cervicais em citologia convencional. Esses valores indicam boa capacidade de ranqueamento, mas a decisão final depende do limiar: na partição retida, o regime de alta sensibilidade reduziu os falsos negativos de 60 para 30 em relação ao limiar 0,50, ao custo de elevar os falsos positivos de 64 para 146. Essa troca é compatível com triagem apenas quando há revisão humana posterior.

A análise por categoria Bethesda mostrou que a simplificação binária não resolve completamente a dificuldade das classes limítrofes. ASC-US foi a principal fonte de erro observada, com 81,7% de acerto entre 115 células, enquanto HSIL e SCC foram mais facilmente recuperadas. A comparação exploratória com ResNet50 também mostrou que a vantagem da ConvNeXt-Tiny está principalmente no ranqueamento, não em todas as métricas dependentes de limiar.

As principais limitações são a ausência de identificadores de paciente na CRIC, que não permite garantir separação clínica completa, a comparação com ResNet50 restrita à partição retida e a ausência de validação externa. Trabalhos futuros devem repetir baselines nos cinco folds agrupados, validar o método em outras bases, incorporar explicabilidade e avançar da célula recortada para localização automática e agregação de evidências no nível da lâmina. Até essas etapas, o método permanece um protótipo de pesquisa para priorização, sem finalidade diagnóstica.

Referências

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., Van Smeden, M., et al. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.

- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255.
- Fang, M., Liao, B., Lei, X., and Wu, F.-X. (2024). A systematic review on deep learning based methods for cervical cell image analysis. *Neurocomputing*, 610:128630.
- Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 1321–1330. PMLR.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.
- Jiang, P., Li, X., Shen, H., Chen, Y., Wang, L., Chen, H., Feng, J., and Liu, J. (2023). A systematic review of deep learning-based cervical cytology screening: From cell identification to whole slide image analysis. *Artificial Intelligence Review*, 56(Suppl 2):2687–2758.
- Kaur, H., Sharma, R., and Kaur, J. (2025). Comparison of deep transfer learning models for classification of cervical cancer from pap smear images. *Scientific Reports*, 15(1):3945.
- Lima, M. V., Britto, M. H. M., and Britto Neto, L. (2025). Classificação de células cervicais cancerígenas com CNNs e ViTs em ensemble para auxílio ao diagnóstico médico. In *Anais do XXV Simpósio Brasileiro de Computação Aplicada à Saúde*, pages 497–508. Sociedade Brasileira de Computação.
- Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., and Xie, S. (2022). A ConvNet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11966–11976.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Mehedi, M. H. K., Khandaker, M., Ara, S., Alam, M. A., Mridha, M. F., and Aung, Z. (2024). A lightweight deep learning method to identify different types of cervical cancer. *Scientific Reports*, 14(1):29446.
- Nayar, R. and Wilbur, D. C. (2015). *The Bethesda System for Reporting Cervical Cytology: Definitions, Criteria, and Explanatory Notes*. Springer.
- Plissiti, M. E., Dimitrakopoulos, P., Sfikas, G., Nikou, C., Krikoni, O., and Charchanti, A. (2018). SI-PaKMeD: A new dataset for feature and image based classification of normal and pathological cervical cells in pap smear images. In *2018 25th IEEE International Conference on Image Processing*, pages 3144–3148.
- Rezende, M. T., Silva, R., Bernardo, F. d. O., Tobias, A. H. G., Oliveira, P. H. C., Machado, T. M., Costa, C. S., Medeiros, F. N. S., Ushizima, D. M., Carneiro, C. M., and Bianchi, A. G. C. (2021). CRIC searchable image database as a public platform for conventional pap smear cytology data. *Scientific Data*, 8(1):151.
- Rodríguez, M., Córdova, C., Benjumed, I., and San Martín, S. (2024). Automated cervical cancer screening using single-cell segmentation and deep learning: Enhanced performance with liquid-based cytology. *Computation*, 12(12):232.
- Singh, D., Vignat, J., Lorenzoni, V., Eslahi, M., Ginsburg, O., Lauby-Secretan, B., Arbyn, M., Basu, P., Bray, F., and Vaccarella, S. (2023). Global estimates of incidence and mortality of cervical cancer in 2020: A baseline analysis of the WHO global cervical cancer elimination initiative. *The Lancet Global Health*, 11(2):e197–e206.
- Xu, L., Cai, F., Fu, Y., and Liu, Q. (2023). Cervical cell classification with deep-learning algorithms. *Medical & Biological Engineering & Computing*, 61(3):821–833.