

Image-Partitioned and Clinically Oriented Binary Classification of Cervical Cells in Conventional Pap Smears with ConvNeXt-Tiny

Anonymous submission

¹Author names and affiliations omitted for double-anonymous review

Abstract. *This work investigates binary triage of cervical cells in conventional Pap smears using ConvNeXt-Tiny and the CRIC Cervix collection. In the primary evaluation, five-fold cross-validation grouped by source image yielded ROC AUC 0.9709 ± 0.0059 and PR AUC 0.9607 ± 0.0121 , with balanced accuracy 0.9091 ± 0.0115 at threshold 0.50 and without test-time augmentation. A ResNet50 baseline trained on the retained partition reached ROC AUC 0.9710, while ConvNeXt-Tiny reached 0.9816 under the same split. In this retained partition, test-time augmentation and temperature scaling supported operational threshold analysis: the high-sensitivity threshold reached 0.9701 sensitivity and 0.8723 specificity, whereas the Youden threshold reached 0.9522 sensitivity and 0.9283 specificity. Subtype analysis at the Youden threshold identified ASC-US as the main difficulty, with 81.7% correct binary decisions among 115 cells. Because CRIC provides no patient identifiers, grouping by image does not guarantee patient-level separation. The method is therefore a research prototype for prioritization, not a diagnostic system.*

Resumo. *Este trabalho investiga a triagem binária de células cervicais em esfregaços convencionais de Papanicolau com ConvNeXt-Tiny e a coleção CRIC Cervix. Na avaliação primária, a validação cruzada em cinco folds agrupada por imagem-fonte produziu AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$, com acurácia balanceada de $0,9091 \pm 0,0115$ no limiar 0,50 e sem aumento de dados no teste. Um baseline ResNet50 treinado na partição retida atingiu AUC ROC de 0,9710, enquanto a ConvNeXt-Tiny atingiu 0,9816 sob a mesma divisão. Nessa partição retida, aumento de dados no teste e escalonamento por temperatura apoiaram a análise de limiares operacionais: o limiar de alta sensibilidade atingiu sensibilidade de 0,9701 e especificidade de 0,8723, enquanto o limiar de Youden atingiu sensibilidade de 0,9522 e especificidade de 0,9283. A análise por subtipo no limiar de Youden identificou ASC-US como a principal dificuldade, com 81,7% de decisões binárias corretas entre 115 células. Como a CRIC não fornece identificadores de paciente, o agrupamento por imagem não garante separação no nível do paciente. O método é, portanto, um protótipo de pesquisa para priorização, não um sistema diagnóstico.*

1. Introdução

O câncer do colo do útero permanece entre as principais causas evitáveis de morbidade e mortalidade por câncer em mulheres. Estimativas globais para 2020 indicam aproximadamente 604 mil novos casos e 342 mil mortes, com maior carga em regiões que

enfrentam restrições de acesso à vacinação, ao rastreamento e ao tratamento oportuno [Singh et al. 2023]. A citologia cervical continua sendo um componente relevante do rastreamento, mas a leitura manual de lâminas é trabalhosa, depende de especialistas e envolve alterações morfológicas que podem ser sutis, especialmente nas categorias limítrofes.

Redes neurais profundas têm apresentado resultados promissores na análise de imagens citológicas. Entretanto, revisões recentes apontam que a comparação entre métodos é dificultada por diferenças de base de dados, preparação da lâmina, tarefa, granularidade dos rótulos e protocolo de validação [Fang et al. 2024]. Um risco particularmente importante surge quando células recortadas da mesma imagem aparecem em treino e teste. Como elas compartilham coloração, aquisição, fundo e artefatos, uma divisão aleatória no nível celular pode produzir uma estimativa excessivamente otimista da generalização.

Além da discriminação, um sistema de apoio à triagem precisa tornar explícita a relação entre falsos negativos e falsos positivos. Um limiar fixo de 0,5 não é necessariamente apropriado para um cenário em que deixar de sinalizar uma célula anormal pode ser mais grave do que encaminhar uma célula normal para revisão. Probabilidades também não devem ser interpretadas como confiança sem avaliação de calibração, pois redes modernas podem ser corretas na ordenação e, ainda assim, superconfiantes [Guo et al. 2017]. Diretrizes como TRIPOD+AI reforçam a necessidade de descrever partições, seleção de limiar, incerteza e uso pretendido de modelos preditivos [Collins et al. 2024].

Este artigo estuda a classificação binária *normal versus anormal* de células da coleção CRIC Cervix, obtidas por citologia convencional. A tarefa é formulada como triagem: reunir ASC-US, LSIL, ASC-H, HSIL e SCC na classe anormal, preservando os subtipos para análise posterior. Utiliza-se ConvNeXt-Tiny pré-treinada, uma arquitetura convolucional modernizada que incorpora decisões de projeto popularizadas por transformadores visuais [Liu et al. 2022].

As contribuições do estudo são quatro. Primeiro, a avaliação primária emprega validação cruzada em cinco folds, com agrupamento por imagem-fonte e retreino do modelo em cada fold. Segundo, uma partição retida complementa a estimativa de variância com análise de limiares operacionais, TTA, calibração e intervalos de confiança por bootstrap agrupado por imagem. Terceiro, a ConvNeXt-Tiny é comparada a uma ResNet50 treinada sob a mesma partição retida, evitando comparação indireta entre bases incompatíveis. Quarto, os erros são estratificados pelas categorias Bethesda originais, revelando onde a simplificação binária permanece difícil.

O objetivo não é propor um diagnóstico autônomo nem comparar arquiteturas em bases incompatíveis. Busca-se oferecer um protocolo reproduzível e clinicamente orientado para avaliar até que ponto um classificador de células pode priorizar regiões suspeitas em imagens convencionais, bem como explicitar as evidências ainda necessárias antes de qualquer uso assistencial. Assim, o diferencial do trabalho está menos em uma nova arquitetura e mais em uma avaliação que combina controle de agrupamento, análise operacional de limiares, incerteza estatística e interpretação por subtipo Bethesda em uma base de citologia convencional.

2. Trabalhos Relacionados

2.1. Bases e tarefas em citologia cervical

Herlev e SIPaKMeD são bases frequentes na classificação de células isoladas. A SIPaKMeD contém imagens de células extraídas de esfregaços de Papanicolau e foi proposta para classificação baseada em atributos e imagens [Plissiti et al. 2018]. Embora úteis para comparação, bases de células isoladas não reproduzem integralmente sobreposição, inflamação, variação de fundo e outros fatores encontrados em exames convencionais.

A CRIC Cervix foi construída a partir de 400 imagens de citologia convencional e contém 11.534 células classificadas por citopatologistas segundo o Sistema Bethesda [Rezende et al. 2021]. A coleção inclui NILM, ASC-US, LSIL, ASC-H, HSIL e SCC, preservando desafios de lâminas reais, como células sobrepostas e elementos inflamatórios. Essa característica torna a CRIC especialmente adequada para estudar generalização entre imagens, mas exige que a dependência entre células da mesma imagem seja considerada no desenho experimental.

2.2. Aprendizado profundo para classificação cervical

A Tabela 1 posiciona estudos recentes que usam redes profundas em citologia cervical [Kaur et al. 2025, Mehedi et al. 2024, Lima et al. 2025, Rodríguez et al. 2024]. A comparação é deliberadamente qualitativa: os resultados não são diretamente intercambiáveis porque variam base, preparação, número de classes, métrica principal e unidade de particionamento. Ainda assim, a tabela evidencia a lacuna explorada neste trabalho: avaliar triagem binária em CRIC com particionamento por imagem, limiares operacionais, incerteza e análise Bethesda.

Tabela 1. Comparação qualitativa com estudos recentes.

Estudo	Base/preparação	Resultado reportado	Diferença para este trabalho
Kaur 2025	Herlev/SIPaKMeD; células isoladas	ResNet50: 95% em Herlev binário	Comparação ampla de arquiteturas, sem foco em CRIC, limiares clínicos ou Bethesda
Mehedi 2024	SIPaKMeD; cinco classes	CCanNet: 98,53% de acurácia	Modelo leve em base isolada; protocolo e tarefa distintos da citologia convencional CRIC
Lima 2025	Herlev/SIPaKMeD; <i>ensemble</i>	98,35% em Herlev binário; 99,73% em SIPaKMeD binário	Forte comparação entre arquiteturas; não avalia CRIC nem erro por Bethesda
Rodríguez 2024	Pap convencional e meio líquido	Pap: sens. 0,688; espec. 0,762	Mostra a dificuldade da citologia convencional; usa tarefa e dados diferentes
Este artigo	CRIC; citologia convencional	CV agrupada: AUC ROC 0,9709 ± 0,0059	Foco em protocolo: agrupamento por imagem, limiares, ICs, calibração e análise Bethesda

Em síntese, a literatura apresenta desempenho elevado, porém frequentemente privilegia acurácia em bases de células isoladas. Este estudo se diferencia menos pela arquitetura isolada e mais pelo protocolo: citologia convencional, partição por imagem, validação cruzada agrupada, comparação local com ResNet50, limiar definido na validação, intervalos de confiança que respeitam agrupamentos e análise de erro preservando a nomenclatura Bethesda.

3. Metodologia

3.1. Base de dados e definição do desfecho

Foram utilizadas as 400 imagens e as 11.534 anotações celulares da CRIC Cervix [Rezende et al. 2021]. A classe normal reúne as 6.779 células rotuladas como negativas para lesão intraepitelial ou malignidade (NILM). A classe anormal reúne 4.755 células: 606 ASC-US, 1.360 LSIL, 925 ASC-H, 1.703 HSIL e 161 SCC. A escolha binária representa um primeiro estágio de priorização e não substitui a classificação Bethesda. A CRIC não disponibiliza identificadores de paciente; portanto, a imagem-fonte é o nível de agrupamento mais alto disponível, mas não assegura separação entre pacientes.

Tabela 2. Composição da CRIC Cervix utilizada no estudo.

Classe binária	Categoria Bethesda	Células	Proporção (%)
Normal	NILM	6.779	58,8
Anormal	ASC-US	606	5,3
Anormal	LSIL	1.360	11,8
Anormal	ASC-H	925	8,0
Anormal	HSIL	1.703	14,8
Anormal	SCC	161	1,4
Total		11.534	100,0

Para cada anotação, foi gerado um recorte RGB de 224×224 pixels centrado na coordenada do núcleo. Recortes que ultrapassavam as bordas foram completados com fundo branco para manter dimensão constante. Não foi realizada segmentação do núcleo ou do citoplasma, permitindo que a rede utilizasse contexto celular local. A Figura 1 ilustra a variabilidade de coloração, textura, agrupamento e contexto presente nos recortes processados.




Figura 1. Exemplos de recortes com rótulo real normal (NILM) e anormal, selecionados da amostra visual gerada pelo pipeline no notebook.

3.2. Particionamento e desenho de avaliação

A unidade de agrupamento foi a imagem original. Um `GroupShuffleSplit` separou 70% das imagens para treino e 30% para um conjunto temporário; este foi dividido igualmente entre validação e teste. Assim, nenhuma imagem-fonte contribuiu com células para mais de uma partição. A Tabela 3 apresenta a distribuição obtida com semente 42.

Tabela 3. Distribuição das células e imagens nas partições.

Partição	Imagens	Normal	Anormal	Total
Treino	280	4.698	2.835	7.533
Validação	60	938	916	1.854
Teste	60	1.143	1.004	2.147

Essa decisão reduz o risco de vazamento por correlação visual. Embora as células sejam as observações classificadas, as imagens são as unidades independentes de aquisição disponíveis; por isso, elas também são usadas como clusters na análise de incerteza.

A avaliação primária de desempenho e variância empregou `StratifiedGroupKFold` com cinco folds, usando a imagem-fonte como grupo e preservando, tanto quanto possível, a proporção das classes. O modelo foi retreinado em cada fold. As predições foram avaliadas no limiar 0,50, sem TTA; essa opção mantém o protocolo executado, mas limita a comparação com a análise mais completa da partição retida.

A partição treino–validação–teste da Tabela 3 foi mantida como análise detalhada complementar. Nela foram estudados TTA, escalonamento por temperatura, limiares selecionados na validação, intervalos de confiança e erros por categoria Bethesda.

3.3. Modelo e treinamento

Foi adotada a `ConvNeXt-Tiny` pré-treinada na ImageNet. A camada classificadora foi substituída por uma camada linear com duas saídas. A `ConvNeXt` moderniza redes convolucionais com blocos, normalizações e escolhas de escala inspiradas no desenvolvimento de transformadores visuais, mantendo operações convolucionais [Liu et al. 2022]. Como comparação interna, uma `ResNet50` pré-treinada também foi treinada e avaliada na mesma partição retida. Essa comparação não substitui a validação cruzada, mas fornece uma referência sob igual divisão treino–validação–teste.

No treino, foram aplicados recorte redimensionado aleatório com escala entre 0,85 e 1,0, espelhamento horizontal, rotação de até 10 graus e pequenas variações de brilho, contraste, saturação e matiz. As imagens foram normalizadas pelas estatísticas da ImageNet. Um `WeightedRandomSampler` equilibrou a exposição às classes sem alterar a distribuição de validação ou teste.

Seguindo a prática de explicitar configuração e custo computacional em estudos comparativos [Lima et al. 2025], a Tabela 4 resume os parâmetros executados. A implementação oficial possui 28,59 milhões de parâmetros; após substituir a cabeça de 1.000 por duas saídas, o modelo usado possui aproximadamente 27,82 milhões. O custo de referência para entrada 224×224 é 4,46 GFLOPs. O melhor checkpoint foi selecionado exclusivamente pela AUC ROC na validação.

Tabela 4. Hiperparâmetros de treinamento e características do protocolo local.

Parâmetro	Configuração	Parâmetro	Configuração
Arquitetura	ConvNeXt-Tiny	Baseline	ResNet50
Entrada	$224 \times 224 \times 3$	Lote	48
Otimizador	AdamW	Taxa inicial	3×10^{-4}
Decaimento	10^{-4}	Épocas máx.	12
Agendador	cossenoidal	<i>Label smoothing</i>	0,03
Amostragem	ponderada	Parâmetros	27,82 M
Custo ref.	4,46 GFLOPs	Seleção	AUC ROC val.

3.4. Predição, limiares e calibração

Na análise da partição retida, foi aplicada *test-time augmentation* (TTA) pela média dos logits da imagem original e de seu espelho horizontal. A calibração por temperatura ajustou um único parâmetro T minimizando entropia cruzada na validação [Guo et al. 2017]. Como o escalonamento por temperatura é monotônico, ele não altera a ordenação das predições nem as AUCs; qualquer mudança de ranqueamento em relação à inferência sem TTA decorre do TTA, não da temperatura.

Foram avaliados três regimes de decisão. O primeiro usa limiar 0,5. O segundo maximiza o índice de Youden na validação, equilibrando sensibilidade e especificidade. O terceiro seleciona, também na validação, o menor custo em falsos positivos entre os pontos que atingem sensibilidade mínima de 0,97. Os limiares resultantes foram 0,287 para Youden e 0,099 para alta sensibilidade. Nenhum limiar foi otimizado no teste.

3.5. Métricas e análise de incerteza

Foram calculadas AUC ROC, AUC precisão–revocação (AUC PR), sensibilidade, especificidade, acurácia balanceada, $F1$ da classe anormal, coeficiente de correlação de Matthews (MCC), kappa de Cohen e *Brier score*. A calibração foi resumida pelo erro esperado de calibração (ECE) em dez intervalos.

Para o regime de Youden, intervalos de confiança de 95% foram estimados com 2.000 réplicas de bootstrap. A reamostragem ocorreu sobre as 60 imagens de teste, com reposição, incluindo em cada réplica todas as células pertencentes às imagens sorteadas. Essa estratégia evita tratar 2.147 células correlatas como observações completamente independentes.

Por fim, as predições binárias foram estratificadas pelas seis categorias Bethesda. Essa análise não transforma o modelo em multiclasse; ela identifica quais subtipos concentram erros e fornece uma interpretação mais útil do que uma única métrica agregada. A Tabela 7 usa as decisões da partição retida no limiar de Youden, 0,287.

4. Resultados

4.1. Validação cruzada agrupada

A validação cruzada agrupada em cinco folds constitui o resultado primário do estudo. No limiar 0,50 e sem TTA, a ConvNeXt-Tiny obteve AUC ROC média de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$. A Tabela 5 resume as métricas agregadas. Como a média pode ocultar trocas operacionais entre falsos negativos e falsos positivos, a Figura 2 separa

sensibilidade e especificidade por fold. A função da figura é mostrar onde a validação cruzada varia: não no ranqueamento global, mas no ponto de decisão binária usado em triagem.

Tabela 5. Resultado primário da validação cruzada em cinco folds agrupada por imagem, com limiar 0,50 e sem TTA. Valores em média $\pm$ desvio-padrão.

Métrica	Resultado
AUC ROC	0,9709 $\pm$ 0,0059
AUC PR	0,9607 $\pm$ 0,0121
Acurácia balanceada	0,9091 $\pm$ 0,0115
Sensibilidade	0,8994 $\pm$ 0,0480
Especificidade	0,9188 $\pm$ 0,0400
<i>F1</i>	0,8926 $\pm$ 0,0128
MCC	0,8189 $\pm$ 0,0208
Kappa	0,8164 $\pm$ 0,0223
<i>Brier score</i>	0,0699 $\pm$ 0,0079




Figura 2. Métricas dependentes do limiar nos cinco folds agrupados. O fold 1 privilegia especificidade e perde sensibilidade; os folds 2 e 3 mostram o comportamento oposto.

A Figura 2 justifica reportar a validação cruzada além da AUC: no fold 1, a sensibilidade cai para 0,8253 enquanto a especificidade chega a 0,9681; nos folds 2 e 3, a recuperação de anormais aumenta, mas com menor especificidade. Portanto, a variação relevante para uso em triagem está no limiar operacional e na composição do fold, não apenas na capacidade de ranqueamento do modelo.

4.2. Análise detalhada em uma partição

Na partição retida, a inferência da ConvNeXt-Tiny com TTA produziu AUC ROC de 0,9832 e AUC PR de 0,9827. A temperatura estimada na validação foi $T = 1,210$ e o *Brier score* foi 0,0473. O ECE passou de 0,0247 antes da transformação para 0,0130 depois dela, indicando melhora de calibração nessa partição. Como o escalonamento por temperatura é monotônico, ele não altera as AUCs; a pequena mudança de ranqueamento em relação à inferência sem TTA decorre do TTA.

4.3. Efeito do limiar operacional

A Figura 3 evidencia a troca entre falsos negativos e falsos positivos. O limiar 0,50 apresentou o maior MCC e a maior acurácia balanceada. O limiar de Youden aumentou a sensibilidade com perda moderada de especificidade. O regime de alta sensibilidade atingiu 0,9701 de sensibilidade, mas reduziu a especificidade para 0,8723. Em um fluxo de triagem, esse ponto poderia ser aceitável caso a prioridade fosse reduzir omissões, transferindo mais casos para revisão humana.




Figura 3. Troca operacional entre sensibilidade, especificidade e MCC para os três limiares avaliados. O regime de alta sensibilidade reduz omissões, mas amplia falsos positivos.

Os intervalos de confiança por bootstrap agrupado por imagem reforçam que a diferença entre 0,50 e Youden é pequena na partição retida. Para o limiar 0,50, a sensibilidade foi 0,9402 (IC95% 0,8801–0,9737), a especificidade foi 0,9440 (IC95% 0,9087–0,9697) e o MCC foi 0,8840 (IC95% 0,8203–0,9261). Para Youden, a sensibilidade foi 0,9522 (IC95% 0,8939–0,9829), a especificidade foi 0,9283 (IC95% 0,8925–0,9561) e o MCC foi 0,8791 (IC95% 0,8150–0,9218). Para o limiar de alta sensibilidade, a sensibilidade foi 0,9701 (IC95% 0,9342–0,9902), a especificidade foi 0,8723 (IC95% 0,8239–0,9139) e o MCC foi 0,8414 (IC95% 0,7766–0,8892).

4.4. Comparação com ResNet50

A comparação interna com ResNet50 foi realizada na mesma partição retida. A ConvNeXt-Tiny apresentou maior capacidade de ranqueamento, com AUC ROC 0,9816 e AUC PR 0,9805, contra 0,9710 e 0,9750 da ResNet50. A ResNet50, por outro lado, obteve maior especificidade, acurácia balanceada e MCC no limiar avaliado. Esse resultado sugere que a ConvNeXt-Tiny ordena melhor as amostras, enquanto a decisão binária depende fortemente do limiar escolhido.

Tabela 6. Comparação entre ConvNeXt-Tiny e ResNet50 na partição retida.

Modelo	AUC ROC	AUC PR	Acc. bal.	Sens.	Espec.	F1	MCC
ConvNeXt-Tiny	0,9816	0,9805	0,9371	0,9373	0,9370	0,9331	0,8738
ResNet50	0,9710	0,9750	0,9401	0,9064	0,9738	0,9362	0,8852

4.5. Representatividade e erros por categoria Bethesda

A composição da partição retida favorece categorias mais facilmente separáveis: HSIL corresponde a 52,7% das células anormais no teste, ante 35,8% no conjunto completo, enquanto LSIL corresponde a 16,4%, ante 28,6% no conjunto completo. Essa super-representação de HSIL e sub-representação de LSIL ajudam a explicar por que os resultados da partição única são superiores às médias da validação cruzada.

No limiar de Youden, a Tabela 7 mostra 92,8% de acerto para NILM, 81,7% para ASC-US, 94,5% para LSIL, 90,2% para ASC-H, 99,4% para HSIL e 100% para SCC. O resultado de ASC-US, baseado em 115 células dessa partição, sugere uma dificuldade relevante, mas não sustenta sozinho uma conclusão populacional. SCC também possui suporte reduzido, com 42 células.

Tabela 7. Acerto binário por categoria Bethesda na partição retida, usando o limiar de Youden (0,287).

Categoria	<i>n</i>	Acerto (%)	IC95% Wilson	<i>P</i> (anormal) média
NILM	1143	92,8	91,2–94,2%	0,091
ASC-US	115	81,7	73,7–87,7%	0,741
LSIL	165	94,5	90,0–97,1%	0,898
ASC-H	153	90,2	84,5–94,0%	0,860
HSIL	529	99,4	98,3–99,8%	0,956
SCC	42	100,0	91,6–100,0%	0,970

5. Discussão

O resultado primário indica que a ConvNeXt-Tiny discrimina células normais e anormais da CRIC com AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$ na validação cruzada agrupada. A estabilidade da AUC entre folds sugere boa capacidade de ranqueamento, mas a sensibilidade variou de 0,8253 a 0,9434. Essa variação é central para a interpretação clínica: em uma tarefa de triagem, a ordenação global pode ser alta e, ainda assim, a taxa de células anormais recuperadas depender da composição das imagens avaliadas. Essa é a principal entrega do estudo: transformar um resultado de classificação em uma análise de uso, variância e erro, em vez de apresentar apenas uma acurácia agregada.

A análise Bethesda oferece uma explicação plausível para parte dessa variabilidade. Na partição retida, HSIL, categoria com 99,4% de acerto, está super-representada entre as anormais, enquanto LSIL está sub-representada e ASC-US apresenta 81,7% de acerto. Assim, partições com mais HSIL tendem a parecer mais favoráveis ao classificador, ao passo que maior presença de LSIL e ASC-US pode reduzir a sensibilidade. Como a composição por subtipo de cada fold não foi modelada formalmente, essa ligação deve ser tratada como hipótese apoiada pela análise estratificada, não como explicação causal demonstrada.

Na partição retida, a comparação com ResNet50 mostra que a ConvNeXt-Tiny foi superior em AUC ROC e AUC PR, mas não dominou todas as métricas dependentes de limiar. A ResNet50 alcançou maior especificidade e MCC na comparação local, enquanto a ConvNeXt-Tiny apresentou maior sensibilidade e melhor ranqueamento. Esse padrão

reforça a separação entre duas perguntas: qual modelo ordena melhor as células por risco e qual ponto operacional produz a melhor decisão binária para um fluxo específico.

Em relação à literatura, a comparação deve usar a validação cruzada agrupada, e não apenas a partição com resultado mais alto. Estudos em Herlev e SIPaKMeD reportaram acurácias elevadas com ResNet50, CCanNet e ensembles [Kaur et al. 2025, Mehedi et al. 2024, Lima et al. 2025], mas diferem em preparação, classes, unidade de particionamento e métrica principal. O resultado médio de AUC ROC 0,9709 na CRIC não estabelece superioridade nem inferioridade diante dessas acurácias. Ele indica, de modo mais restrito, que um protocolo agrupado por imagem em citologia convencional ainda permite desempenho competitivo. O desempenho inferior reportado por Rodríguez et al. em esfregaços convencionais reforça que essa preparação pode ser mais desafiadora que a citologia em meio líquido [Rodríguez et al. 2024].

A calibração também deve ser interpretada no escopo da partição retida. O escalonamento por temperatura reduziu o ECE de 0,0247 para 0,0130, mas esse ganho não foi avaliado por validação cruzada. Além disso, uma transformação monotônica não altera AUC; a diferença de ranqueamento observada na análise detalhada decorre do TTA. Em cenários de uso clínico, probabilidades calibradas são relevantes para priorização e comunicação de incerteza, mas exigem validação externa e amostras maiores.

5.1. Recomendações para estudos comparáveis

Uma contribuição adicional do estudo é explicitar escolhas de avaliação que deveriam ser reportadas em trabalhos futuros com células cervicais recortadas. Diretrizes recentes para modelos preditivos e IA em imagem médica recomendam declarar o uso pretendido, a fonte dos dados, o nível de particionamento, as métricas e sua incerteza, além das limitações de generalização [Collins et al. 2024, Tejani et al. 2024]. No contexto da CRIC, esses itens são particularmente importantes porque múltiplas células podem compartilhar a mesma imagem, lâmina, coloração e artefatos de aquisição.

Tabela 8. Elementos mínimos recomendados para avaliação de triagem celular em citologia cervical convencional.

Elemento	Risco mitigado	Como foi tratado neste estudo
Unidade de partição	Vazamento entre recortes visualmente correlatos	Separação por imagem-fonte e validação cruzada agrupada
Métrica primária	Seleção oportunista da partição mais favorável	AUC ROC, AUC PR e métricas de decisão reportadas como média $\pm$ desvio-padrão
Limiar operacional	Confundir ranqueamento com decisão clínica	Comparação entre 0,50, Youden e regime de alta sensibilidade
Incerteza	Tratar células correlatas como independentes	Bootstrap agrupado por imagem e intervalos de Wilson por subtipo
Análise por subtipo	Ocultar falhas em categorias limítrofes	Estratificação por NILM, ASC-US, LSIL, ASC-H, HSIL e SCC

Essa estrutura também ajuda a interpretar diferenças entre estudos. Uma acurácia elevada em Herlev ou SIPaKMeD pode ser útil como referência de arquitetura, mas não substitui um protocolo que declare o nível de separação dos dados, o regime de decisão e a composição dos subtipos. Para a CRIC, a ausência de identificadores de paciente torna inadequado apresentar o particionamento por imagem como solução definitiva; ele deve ser descrito como o melhor controle disponível na base, não como garantia clínica.

5.2. Limitações e uso responsável

A principal limitação de validade está no nível de independência dos dados. O agrupamento por imagem reduz o compartilhamento direto de recortes entre treino e teste, mas não garante separação por paciente, pois a CRIC não fornece identificadores individuais e suas 400 imagens provêm de um número menor de lâminas. Além disso, a ResNet50 foi treinada na mesma partição retida, mas não foi repetida em todos os folds; portanto, a comparação entre arquiteturas deve ser lida como análise complementar.

Também há limitações de escopo. A tarefa binária avalia recortes centrados em núcleos anotados, não a leitura de uma lâmina completa. O preenchimento branco em bordas pode funcionar como atalho visual, e recortes de regiões sobrepostas podem conter núcleos vizinhos que influenciam a decisão atribuída à célula central. Não houve validação externa em outra instituição, equipamento ou população, o que restringe conclusões sobre generalização.

Por essas razões, o sistema deve ser entendido como protótipo de pesquisa para priorização: ele recebe uma célula já localizada e devolve uma pontuação para revisão. Um fluxo completo ainda necessita localizar células, lidar com campos sem anotações, agregar evidências no nível da lâmina e incorporar supervisão humana. A coleção CRIC é pública, anonimizada e distribuída para pesquisa [Rezende et al. 2021]; o modelo não foi validado prospectivamente e não deve ser usado para diagnóstico ou exclusão de casos.

6. Conclusão

A avaliação primária por validação cruzada agrupada mostrou AUC ROC de $0,9709 \pm 0,0059$, aproximadamente $0,97 \pm 0,01$, para a ConvNeXt-Tiny na triagem binária de células cervicais em citologia convencional. A variação da sensibilidade entre 0,8253 e 0,9434 evidencia a importância de retreinar e avaliar o modelo em múltiplas partições por imagem. Em uma partição retida, a análise com TTA alcançou AUC ROC 0,9832 e permitiu explorar pontos operacionais, incluindo sensibilidade 0,9701 com especificidade 0,8723.

A comparação local com ResNet50 indica vantagem da ConvNeXt-Tiny em ranqueamento, mas não em todas as métricas dependentes de limiar. A análise Bethesda aponta ASC-US como a principal dificuldade observada, com 81,7% de acerto entre 115 células na partição retida, resultado que deve ser confirmado em folds e bases adicionais. A agenda futura inclui selecionar limiares por fold e aplicar TTA na validação cruzada, repetir baselines sob o mesmo protocolo agrupado, avaliar calibração com mais amostras, incorporar explicabilidade e realizar validação externa. Também são necessários localização automática das células e agregação das evidências no nível da lâmina. Até essas etapas, o método permanece um protótipo de pesquisa para priorização, sem finalidade diagnóstica.

Disponibilidade de Dados e Código

A CRIC Cervix está disponível publicamente conforme descrito por [Rezende et al. 2021]. O código, os checkpoints e os artefatos de reprodução serão disponibilizados em repositório público.

Referências

- Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., Van Smeden, M., et al. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.
- Fang, M., Liao, B., Lei, X., and Wu, F.-X. (2024). A systematic review on deep learning based methods for cervical cell image analysis. *Neurocomputing*, 610:128630.
- Guo, C., Pleiss, G., Sun, Y., and Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 1321–1330. PMLR.
- Kaur, H., Sharma, R., and Kaur, J. (2025). Comparison of deep transfer learning models for classification of cervical cancer from pap smear images. *Scientific Reports*, 15(1):3945.
- Lima, M. V., Britto, M. H. M., and Britto Neto, L. (2025). Classificação de células cervicais cancerígenas com CNNs e ViTs em ensemble para auxílio ao diagnóstico médico. In *Anais do XXV Simpósio Brasileiro de Computação Aplicada à Saúde*, pages 497–508. Sociedade Brasileira de Computação.
- Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., and Xie, S. (2022). A ConvNet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11966–11976.
- Mehedi, M. H. K., Khandaker, M., Ara, S., Alam, M. A., Mridha, M. F., and Aung, Z. (2024). A lightweight deep learning method to identify different types of cervical cancer. *Scientific Reports*, 14(1):29446.
- Plissiti, M. E., Dimitrakopoulos, P., Sfikas, G., Nikou, C., Krikoni, O., and Charchanti, A. (2018). SIPaKMeD: A new dataset for feature and image based classification of normal and pathological cervical cells in pap smear images. In *2018 25th IEEE International Conference on Image Processing*, pages 3144–3148.
- Rezende, M. T., Silva, R., Bernardo, F. d. O., Tobias, A. H. G., Oliveira, P. H. C., Machado, T. M., Costa, C. S., Medeiros, F. N. S., Ushizima, D. M., Carneiro, C. M., and Bianchi, A. G. C. (2021). CRIC searchable image database as a public platform for conventional pap smear cytology data. *Scientific Data*, 8(1):151.
- Rodríguez, M., Córdova, C., Benjumeda, I., and San Martín, S. (2024). Automated cervical cancer screening using single-cell segmentation and deep learning: Enhanced performance with liquid-based cytology. *Computation*, 12(12):232.
- Singh, D., Vignat, J., Lorenzoni, V., Eslahi, M., Ginsburg, O., Lauby-Secretan, B., Arbyn, M., Basu, P., Bray, F., and Vaccarella, S. (2023). Global estimates of incidence and mortality of cervical cancer in 2020: A baseline analysis of the WHO global cervical cancer elimination initiative. *The Lancet Global Health*, 11(2):e197–e206.
- Tejani, A. S., Klontzas, M. E., Gatti, A. A., Mongan, J. T., Moy, L., Park, S., Kahn, C. E., and Panel, C. . U. (2024). Checklist for artificial intelligence in medical imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, 6(4):e240300.