

Triagem Binária de Células Cervicais em Esfregaços Convencionais com ConvNeXt-Tiny e Particionamento por Imagem

Karielly de Carvalho¹, João Antônio Leal de Miranda¹
Romuere Rodrigues Veloso e Silva¹

¹ Universidade Federal do Piauí (UFPI) – Campus Senador Helvídio Nunes de Barros
Picos – PI – Brasil

{karielly.carvalho, joaoantonio, romuere}@ufpi.edu.br

Resumo. *Este trabalho avalia a triagem binária de células cervicais em esfregaços convencionais de Papanicolau usando ConvNeXt-Tiny na coleção CRIC Cervix. O desenho experimental emprega validação cruzada em cinco folds agrupada por imagem-fonte, de modo que células da mesma imagem não sejam compartilhadas entre treino e avaliação dentro de um fold. Como comparação complementar, uma ResNet-50 foi treinada no mesmo particionamento. No limiar 0,50 e sem test-time augmentation, a ConvNeXt-Tiny obteve AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$, enquanto a ResNet-50 obteve AUC ROC de $0,9668 \pm 0,0082$ e AUC PR de $0,9513 \pm 0,0186$. As métricas dependentes do limiar foram muito próximas: acurácia balanceada de $0,9091 \pm 0,0115$ para ConvNeXt-Tiny e $0,9105 \pm 0,0139$ para ResNet-50. Os resultados apoiam a ConvNeXt-Tiny como modelo principal, com desempenho semelhante ao comparador e maior AUC média; as diferenças entre as duas arquiteturas não foram estatisticamente significativas nos cinco folds. Como a CRIC não fornece identificadores de paciente, o agrupamento por imagem é o controle de independência mais forte disponível neste estudo, mas não garante separação no nível do paciente.*

1. Introdução

O câncer do colo do útero permanece entre as principais causas evitáveis de morbidade e mortalidade por câncer em mulheres. Estimativas globais para 2020 indicam aproximadamente 604 mil novos casos e 342 mil mortes, com maior carga em regiões que enfrentam restrições de acesso à vacinação, ao rastreamento e ao tratamento oportuno [Singh et al. 2023]. A citologia cervical continua sendo um componente relevante de programas de rastreamento, mas a leitura manual de lâminas é trabalhosa, depende de especialistas e envolve alterações morfológicas sutis.

Redes neurais profundas têm apresentado resultados promissores na análise de imagens citológicas [Jiang et al. 2023, Fang et al. 2024]. Entretanto, a comparação entre métodos é dificultada por diferenças de base, preparação da lâmina, tarefa, granularidade dos rótulos e protocolo de validação [Fang et al. 2024]. Um risco central ocorre quando células recortadas da mesma imagem aparecem em treino e avaliação: elas compartilham coloração, aquisição, fundo e artefatos, podendo superestimar a generalização para imagens não vistas. Por isso, diretrizes de relato para modelos preditivos e inteligência artificial em

imagens médicas recomendam explicitar fonte dos dados, unidade de análise, nível de separação entre conjuntos e uso pretendido do sistema [Collins et al. 2024, Tejani et al. 2024].

Este artigo estuda a classificação binária *normal versus anormal* de células da coleção CRIC Cervix. ASC-US, LSIL, ASC-H, HSIL e SCC compõem a classe anormal, enquanto NILM compõe a classe normal. A contribuição principal é avaliar a ConvNeXt-Tiny [Liu et al. 2022] com validação cruzada agrupada por imagem-fonte, reportando média, desvio-padrão e variação fold a fold. Para contextualizar o desempenho, inclui-se a ResNet-50 [He et al. 2016] como comparador complementar treinado nos mesmos folds.

2. Trabalhos Relacionados

2.1. Bases e tarefas em citologia cervical

Bases como Herlev e SIPaKMeD são frequentes em estudos de classificação cervical [Jiang et al. 2023, Fang et al. 2024]. A SIPaKMeD reúne células extraídas de esfregaços de Papanicolau para classificação por atributos e imagens [Plissiti et al. 2018]. Embora úteis para comparação, bases de células isoladas não reproduzem integralmente sobreposição, inflamação, variação de fundo e outros fatores encontrados em exames convencionais.

A CRIC Cervix foi construída a partir de 400 imagens de citologia convencional e contém 11.534 células classificadas por citopatologistas [Rezende et al. 2021]. A coleção inclui NILM, ASC-US, LSIL, ASC-H, HSIL e SCC, preservando desafios de lâminas reais, como células sobrepostas e elementos inflamatórios. Por isso, é útil para estudar variação entre imagens, desde que a dependência entre células da mesma imagem seja considerada. Essa característica diferencia a CRIC de bases compostas por células isoladas: o modelo pode explorar tanto atributos celulares quanto padrões de aquisição, coloração e fundo compartilhados por uma mesma imagem. Assim, o particionamento por imagem é parte central do desenho experimental.

2.2. Aprendizado profundo para classificação cervical

Estudos recentes reportam desempenho elevado com redes profundas em Herlev, SIPaKMeD e outras bases de citologia cervical. Kaur et al. compararam modelos de transferência e reportaram 95% de acurácia com ResNet50 em Herlev binário [Kaur et al. 2025]; Mehedi et al. obtiveram 98,53% de acurácia com CCanNet em SIPaKMeD de cinco classes [Mehedi et al. 2024]; e Lima et al. reportaram 98,35% em Herlev binário e 99,73% em SIPaKMeD binário com *ensembles* [Lima et al. 2025]. Especificamente com ConvNeXt, Tang et al. reportaram alta precisão na classificação de lesões precursoras cervicais, evidenciando o potencial dessa família em citologia [Tang et al. 2023]. Esses resultados são relevantes como contexto, mas não são diretamente comparáveis ao presente estudo por diferenças de base, preparação, número de classes, métrica principal e unidade de particionamento. Assim, mais do que confrontar percentuais absolutos, a comparação com a literatura deve considerar se a separação entre treino e teste ocorre no nível de célula, imagem, lâmina ou paciente.

Em citologia convencional, Rodríguez et al. reportaram sensibilidade 0,688 e especificidade 0,762 em esfregaços de Papanicolau, indicando maior dificuldade que em bases de células isoladas ou citologia em meio líquido [Rodríguez et al. 2024]. Este trabalho se diferencia pelo protocolo: CRIC, separação por imagem, validação cruzada

agrupada, ajuste fino da ConvNeXt-Tiny em cinco folds e apresentação explícita da variabilidade entre partições.

Além do desempenho, o relato de estudos de IA em saúde deve permitir interpretação crítica do risco de viés, da independência dos dados e da aplicabilidade do modelo [Collins et al. 2024, Tejani et al. 2024]. Essa preocupação é especialmente relevante em citologia baseada em recortes, pois várias amostras podem vir do mesmo campo microscópico.

3. Metodologia

3.1. Base de dados e desfecho

Foram utilizadas as 400 imagens e as 11.534 anotações celulares da CRIC Cervix [Rezende et al. 2021]. A classe normal reúne 6.779 células NILM. A classe anormal reúne 4.755 células: 606 ASC-US, 1.360 LSIL, 925 ASC-H, 1.703 HSIL e 161 SCC, segundo o Sistema Bethesda [Nayar and Wilbur 2015]. A escolha binária representa um primeiro estágio de priorização e não substitui a classificação Bethesda.

Para cada anotação, foi gerado um recorte RGB de 224×224 pixels centrado na coordenada do núcleo. Recortes que ultrapassavam as bordas foram completados com fundo branco. Não foi realizada segmentação do núcleo ou do citoplasma, permitindo que a rede utilizasse o contexto celular local. A Figura 1 ilustra recortes reais utilizados no treinamento e na avaliação.




Figura 1. Exemplos de recortes reais da CRIC Cervix usados no protocolo binário. A linha superior mostra células NILM; a inferior inclui categorias Bethesda anormais.

3.2. Validação cruzada agrupada

A unidade de agrupamento foi a imagem original. A avaliação empregou `StratifiedGroupKFold` com cinco folds, usando a imagem-fonte como grupo e preservando, tanto quanto possível, a proporção das classes em cada divisão. Em cada fold, todas as células de uma mesma imagem permanecem juntas: ou no conjunto de treino do fold, ou no conjunto de avaliação do fold. Essa decisão reduz vazamento por correlação visual entre recortes da mesma imagem. As divisões foram geradas com semente fixa (42) e reutilizadas para o modelo principal e para o comparador, garantindo que diferenças

observadas não fossem causadas por sorteios distintos dos folds. A comparação é, portanto, pareada no nível do fold.

A ConvNeXt-Tiny foi o modelo principal do estudo. Para comparação complementar, uma ResNet-50 foi treinada e avaliada nos mesmos folds. Dentro do conjunto de treino de cada fold, um `GroupShuffleSplit` separou uma validação interna agrupada por imagem, usada somente para selecionar o melhor checkpoint pela AUC ROC. O conjunto de avaliação do fold não participou dessa seleção. As predições foram avaliadas no limiar 0,50 e sem *test-time augmentation*. A Figura 2 resume o fluxo experimental.

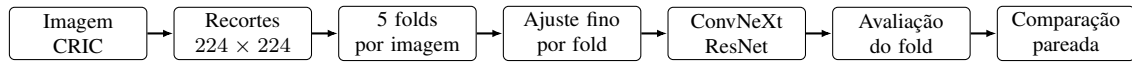


Figura 2. Fluxo do protocolo: a ConvNeXt-Tiny é avaliada em validação cruzada agrupada por imagem, e a ResNet-50 é usada como comparador complementar nos mesmos folds.

3.3. Modelos e treinamento

A arquitetura proposta foi ConvNeXt-Tiny [Liu et al. 2022], pré-treinada na ImageNet [Deng et al. 2009] e com a cabeça substituída por uma camada linear de duas saídas. A ResNet-50 [He et al. 2016] recebeu a mesma adaptação e foi usada apenas como referência arquitetural. O ajuste fino utilizou AdamW [Loshchilov and Hutter 2019], taxa inicial 3×10^{-4} , decaimento 10^{-4} , *label smoothing* 0,03, lote 48 e agendador cossenoidal. No treino, foram aplicados recorte redimensionado aleatório, espelhamento horizontal, rotação de até 10 graus e pequenas variações de cor; na avaliação, apenas redimensionamento e normalização pelas estatísticas da ImageNet.

Os folds da ConvNeXt-Tiny haviam sido ajustados inicialmente com teto de 12 épocas. A análise dos históricos mostrou que o melhor checkpoint por AUC de validação ocorreu nas épocas 1, 3, 3, 4 e 6, conforme o fold. Portanto, a ResNet-50 foi ajustada com teto de 6 épocas e parada antecipada de paciência 2, mantendo o mesmo critério de seleção. Essa decisão reduz custo computacional e permanece dentro da janela efetiva em que a ConvNeXt-Tiny atingiu seus melhores checkpoints; assim, a comparação prioriza o desempenho no mesmo particionamento, e não o custo de treinamento das arquiteturas.

Todos os artefatos foram preservados por fold: definição das imagens em cada divisão, histórico de treinamento, checkpoint selecionado e métricas do conjunto de avaliação. O treinamento foi executado em GPU NVIDIA RTX 3060; a ConvNeXt-Tiny e a ResNet-50 possuem cerca de 28 e 25 milhões de parâmetros, respectivamente. Esse registro favorece reprodutibilidade e segue recomendações de relato para estudos de modelos preditivos aplicados à saúde [Collins et al. 2024, Tejani et al. 2024].

3.4. Métricas

Foram calculadas AUC ROC, AUC precisão–revocação (AUC PR), sensibilidade, especificidade, acurácia balanceada, *F1* da classe anormal, coeficiente de correlação de Matthews (MCC), kappa de Cohen e *Brier score*. Todas as métricas foram calculadas separadamente no conjunto de avaliação de cada fold e resumidas como média e desvio-padrão.

4. Resultados

A Tabela 1 resume o desempenho médio nos cinco folds agrupados por imagem. A ConvNeXt-Tiny, modelo central deste estudo, obteve AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$. Esses valores indicam alta capacidade de ranquear células normais e anormais antes da escolha de um limiar operacional. A comparação complementar com ResNet-50 ficou muito próxima, com AUC ROC de $0,9668 \pm 0,0082$ e AUC PR de $0,9513 \pm 0,0186$.

Tabela 1. Desempenho da ConvNeXt-Tiny e comparação complementar com ResNet-50 por validação cruzada agrupada. Valores em média $\pm$ desvio-padrão, limiar 0,50 e sem TTA.

Métrica	ConvNeXt-Tiny	ResNet-50
AUC ROC	$0,9709 \pm 0,0059$	$0,9668 \pm 0,0082$
AUC PR	$0,9607 \pm 0,0121$	$0,9513 \pm 0,0186$
Acurácia balanceada	$0,9091 \pm 0,0115$	$0,9105 \pm 0,0139$
Sensibilidade	$0,8994 \pm 0,0480$	$0,9001 \pm 0,0344$
Especificidade	$0,9188 \pm 0,0400$	$0,9210 \pm 0,0264$
<i>F1</i>	$0,8926 \pm 0,0128$	$0,8943 \pm 0,0161$
MCC	$0,8189 \pm 0,0208$	$0,8205 \pm 0,0262$
Kappa	$0,8164 \pm 0,0223$	$0,8195 \pm 0,0271$
<i>Brier score</i>	$0,0699 \pm 0,0079$	$0,0671 \pm 0,0096$

Nas métricas calculadas no limiar 0,50, os modelos apresentaram comportamento operacional praticamente equivalente. A ResNet-50 teve pequena vantagem média em acurácia balanceada (0,9105 contra 0,9091), sensibilidade (0,9001 contra 0,8994), especificidade (0,9210 contra 0,9188), *F1*, MCC e Kappa. Entretanto, essas diferenças são pequenas diante da variabilidade entre folds. Um teste t pareado nos cinco folds não indicou diferença estatisticamente significativa entre as arquiteturas em nenhuma métrica (AUC ROC $p = 0,29$; AUC PR $p = 0,10$; acurácia balanceada, sensibilidade, especificidade e MCC com $p > 0,80$), resultado corroborado pelo teste de Wilcoxon pareado. Por isso, a leitura principal dos resultados não deve ser a de uma superioridade operacional ampla da ResNet-50, mas a de que a ConvNeXt-Tiny mantém desempenho equivalente em decisão binária e maior AUC média, preservando o foco do protocolo proposto.

A AUC ROC e a AUC PR avaliam a ordenação das células por suspeição antes da fixação de um ponto de corte, enquanto sensibilidade, especificidade e *F1* dependem do limiar adotado; assim, o limiar 0,50 é configuração experimental padronizada entre modelos, não recomendação clínica definitiva. O *Brier score* foi próximo entre as arquiteturas (0,0699 e 0,0671), sugerindo erro probabilístico semelhante, embora análise formal de calibração ainda seja necessária.




Figura 3. Comparação complementar com ResNet-50. À esquerda, AUC ROC por fold. À direita, médias de métricas selecionadas na validação cruzada.

A Figura 3 evidencia que a diferença entre as arquiteturas não é uniforme. A ResNet-50 superou a ConvNeXt-Tiny em AUC ROC apenas no fold 1 (+0,0080), enquanto a ConvNeXt-Tiny ficou acima nos folds 2, 3, 4 e 5. Em acurácia balanceada, a ResNet-50 foi superior nos folds 1, 2 e 3, enquanto a ConvNeXt-Tiny foi superior nos folds 4 e 5. O maior ganho operacional da ResNet-50 ocorreu no fold 1, com aumento de sensibilidade de +0,1032; a maior perda ocorreu no fold 2, com redução de -0,0419 na sensibilidade, compensada por aumento de especificidade de +0,0567.




Figura 4. Exemplos qualitativos de predições da ConvNeXt-Tiny. As probabilidades correspondem à classe anormal; valores próximos de 0 indicam maior confiança em normalidade e valores próximos de 1 indicam maior confiança em anormalidade. A figura é ilustrativa e não substitui as métricas calculadas nos folds.

A Figura 4 complementa a análise quantitativa com predições corretas e erros próximos ao limiar. Os falsos positivos tendem a probabilidades intermediárias ou moderadamente altas, coerentes com estruturas nucleares salientes em alguns recortes; os falsos negativos concentram-se em amostras anormais com probabilidade próxima de 0,50 ou menor, quando a evidência morfológica do recorte isolado é insuficiente. Em conjunto, a ConvNeXt-Tiny apresenta desempenho médio elevado, mas a triagem automática deve ser interpretada como ferramenta de priorização e apoio, não como substituto direto da avaliação citopatológica.

5. Conclusão

Este trabalho avaliou a ConvNeXt-Tiny na triagem binária de células cervicais da CRIC Cervix usando validação cruzada em cinco folds agrupada por imagem. O modelo apresentou AUC ROC de $0,9709 \pm 0,0059$ e AUC PR de $0,9607 \pm 0,0121$. A comparação complementar com ResNet-50 nos mesmos folds mostrou desempenho operacional muito próximo, mas menor AUC ROC e AUC PR médias para a ResNet-50. As diferenças em sensibilidade, especificidade e acurácia balanceada foram pequenas e variaram entre folds, indicando que a composição das imagens e o limiar operacional também influenciam o desempenho observado.

A análise reforça a importância de reportar média, desvio-padrão e variação fold a fold em estudos com recortes celulares. O particionamento por imagem reduz vazamento entre treino e avaliação e torna a comparação entre ConvNeXt-Tiny e ResNet-50 mais controlada, pois ambas as arquiteturas enfrentam os mesmos subconjuntos de imagens. Ainda assim, como a CRIC não fornece identificadores de paciente, o protocolo não garante independência no nível do paciente ou da lâmina. Ademais, a ResNet-50 foi ajustada com orçamento de épocas menor, restrito à janela em que a ConvNeXt-Tiny alcançou seus melhores checkpoints; embora isso padronize o critério de seleção, uma comparação com orçamento idêntico permanece como trabalho futuro.

Em relação à literatura, o resultado deve ser lido com cautela: acurácias elevadas reportadas em Herlev, SIPaKMeD e outras bases não são diretamente intercambiáveis com a CRIC, que contém citologia convencional com maior variação visual, sobreposição celular e fundo heterogêneo. A contribuição deste trabalho está menos em comparar números absolutos com bases distintas e mais em estabelecer uma avaliação reproduzível, agrupada por imagem e pareada entre arquiteturas.

Os resultados devem ser interpretados como evidência experimental para priorização celular, não como validação clínica de um sistema diagnóstico. Trabalhos futuros devem avaliar calibração, escolha de limiar, validação externa, análise por categoria Bethesda, detecção em campos completos e agregação no nível da lâmina. Código, configurações e materiais complementares: <https://github.com/Kariellyy/Pesquisa-Karielly>.

Referências

- Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., Van Smeden, M., et al. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378.
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., and Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255.
- Fang, M., Liao, B., Lei, X., and Wu, F.-X. (2024). A systematic review on deep learning based methods for cervical cell image analysis. *Neurocomputing*, 610:128630.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.

- Jiang, P., Li, X., Shen, H., Chen, Y., Wang, L., Chen, H., Feng, J., and Liu, J. (2023). A systematic review of deep learning-based cervical cytology screening: From cell identification to whole slide image analysis. *Artificial Intelligence Review*, 56(Suppl 2):2687–2758.
- Kaur, H., Sharma, R., and Kaur, J. (2025). Comparison of deep transfer learning models for classification of cervical cancer from pap smear images. *Scientific Reports*, 15(1):3945.
- Lima, M. V., Britto, M. H. M., and Britto Neto, L. (2025). Classificação de células cervicais cancerígenas com CNNs e ViTs em ensemble para auxílio ao diagnóstico médico. In *Anais do XXV Simpósio Brasileiro de Computação Aplicada à Saúde*, pages 497–508. Sociedade Brasileira de Computação.
- Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., and Xie, S. (2022). A ConvNet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11966–11976.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Mehedi, M. H. K., Khandaker, M., Ara, S., Alam, M. A., Mridha, M. F., and Aung, Z. (2024). A lightweight deep learning method to identify different types of cervical cancer. *Scientific Reports*, 14(1):29446.
- Nayar, R. and Wilbur, D. C. (2015). *The Bethesda System for Reporting Cervical Cytology: Definitions, Criteria, and Explanatory Notes*. Springer.
- Plissiti, M. E., Dimitrakopoulos, P., Sfikas, G., Nikou, C., Krikoni, O., and Charchanti, A. (2018). SIPaKMeD: A new dataset for feature and image based classification of normal and pathological cervical cells in pap smear images. In *2018 25th IEEE International Conference on Image Processing*, pages 3144–3148.
- Rezende, M. T., Silva, R., Bernardo, F. d. O., Tobias, A. H. G., Oliveira, P. H. C., Machado, T. M., Costa, C. S., Medeiros, F. N. S., Ushizima, D. M., Carneiro, C. M., and Bianchi, A. G. C. (2021). CRIC searchable image database as a public platform for conventional pap smear cytology data. *Scientific Data*, 8(1):151.
- Rodríguez, M., Córdova, C., Benjumeda, I., and San Martín, S. (2024). Automated cervical cancer screening using single-cell segmentation and deep learning: Enhanced performance with liquid-based cytology. *Computation*, 12(12):232.
- Singh, D., Vignat, J., Lorenzoni, V., Eslahi, M., Ginsburg, O., Lauby-Secretan, B., Arbyn, M., Basu, P., Bray, F., and Vaccarella, S. (2023). Global estimates of incidence and mortality of cervical cancer in 2020: A baseline analysis of the WHO global cervical cancer elimination initiative. *The Lancet Global Health*, 11(2):e197–e206.
- Tang, J., Zhang, T., Gong, Z., and Huang, X. (2023). High precision cervical precancerous lesion classification method based on ConvNeXt. *Bioengineering*, 10(12):1424.
- Tejani, A. S., Klontzas, M. E., Gatti, A. A., Mongan, J. T., Moy, L., Park, S., Kahn, C. E., and CLAIM 2024 Update Panel (2024). Checklist for artificial intelligence in medical imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, 6(4):e240300.